

FACULTAD DE ESTUDIOS ESTADÍSTICOS

Estudio Comparativo: Modelos Supervisados

Predicción de suscripción a depósitos a plazo fijo

| Índice del Proyecto

- 1 Introducción y Datos
- 2 Preparación y Depuración
- 3 Modelos GLM (y Regularización)
- 4 Árboles de Clasificación

- 5 Random Forest
- 6 Gradient Boosting
- 7 Comparativa Final
- 8 Conclusiones


1. El Problema de Negocio

Contexto

Datos de campaña de marketing directo de un banco portugués (45.211 obs).

Objetivo: Predecir la variable binaria y (suscripción yes/no).





Optimizar recursos llamando solo a clientes con alta probabilidad.



2. Preparación de Datos

Tratamiento

- **Balanceo:** Submuestreo 50/50 (10.000 obs).
- **Outliers:** Conservados en Age/Balance (patrimonio). Eliminados en Duration/Campaign.
- **Ingeniería:** Variable prev_contact y weekday.



3. Modelo GLM

Regresión Logística

GLM: Modelo Inicial

Análisis de Tipo II

Modelo inicial saturado con 49 parámetros.

Mediante ajuste manual iterativo, reducimos la complejidad eliminando variables no significativas.

Resultado Manual: 44 parámetros.




$y \sim \text{job} + \text{marital} + \text{education} + \text{balance} + \text{housing} + \text{loan} + \text{contact} + \text{month} + \text{duration} + \text{campaign} + \text{outcome} + \text{weekday}$

GLM: Selección Automática

Forward Stepwise y Backward: AIC vs BIC

- **AIC:** Penalización suave. Resultado: 45 parámetros.
- **BIC:** Penalización fuerte ($\log(n)$). Resultado: 26 parámetros.

BIC favorece la parsimonia, eliminando ruido innecesario.




GLM: Validación Cruzada

Elección del Ganador

Comparamos los 3 candidatos (Manual, AIC, BIC) usando Cross-Validation.

Al ser el rendimiento prácticamente idéntico, nos quedamos con el **BIC** por ser el más simple.




GLM: Regularización (Lasso & Ridge)

Modelos Penalizados

Para gestionar la multicolinealidad, aplicamos penalización sobre los coeficientes (λ).

- **Ridge** ($\alpha=0$): Reduce coeficientes, no elimina.
- **Lasso** ($\alpha=1$): Selección de variables (coeficientes a cero).

Resultado: El modelo Lasso (optimizado por CV y regla 1se) valida que un subconjunto reducido de variables es suficiente (AUC ~ 0.91).



Modelo	α	λ	$\log(\lambda)$	Nº parámetros	AUC (CV)
s30	1	0.01384	-4.2802	21	0.9042

GLM: Modelo Definitivo

Métricas (Test)

- **AUC:** 0.9085
- **Accuracy:** 82.9%

Interpretación (Odds Ratio)

- **Duración:** +0.6% prosib/seg.
- **Mes:** Marzo (x19) y Sept (x17) disparan la posibilidad.



4. Árboles de Clasificación

Árbol: Modelo Inicial

El Árbol Saturado

Ajuste con minbucket bajo (0.5%).

Genera un árbol de **31 hojas**.

Diagnóstico: **Sobreajuste**. Memoriza el ruido del train.




Árbol: Poda (Pruning)

Buscando el Equilibrio

Analizamos el error de validación frente a la complejidad (cp).

El punto óptimo se encuentra en **16 hojas**. Podar más perdería información; podar menos mantendría ruido.




Árbol: Modelo Final

Reglas Clave

Regla de Oro: Duration > 441s implica muy alta probabilidad de éxito.

- **AUC Test:** 0.8784
- Menos preciso que GLM, pero muy visual para negocio.





5. Random Forest

RF: Inicialización

Estabilización (OOB)

Analizamos el error Out-of-Bag para decidir el número de árboles.

El modelo converge rápidamente. Fijamos **100 árboles** para maximizar eficiencia sin perder precisión.





RF: Ajuste de Hiperparámetros

Grid Search

Optimizamos:

- **Node Size:** 1% (Mejor que 5%).
- **Mtry:** 7 variables candidatas por nodo.

Esta combinación maximiza Kappa y minimiza el error.



RF: Modelo Final

Salto de Calidad

Modelo robusto con gran capacidad de generalización

Train vs Test

AUC



Kappa



Accuracy

0.8602



Kappa

0.7185



Sensitivity

0.8901



Specificity

0.8264





RF: Importancia de Variables

Drivers del Modelo

Random Forest revela qué variables pesan más en la decisión.

Duration domina, seguida de **Month** y **Poutcome**.

Las variables demográficas (edad, trabajo) tienen poco impacto.




6. Gradient Boosting

Boosting: Early Stopping

Evitar el Sobreajuste

En boosting, entrenar demasiados árboles perjudica.

Monitorizamos la **Deviance** en validación: el mínimo se alcanza en la iteración 585 (modelo inicial) o 341 (modelo final).




Boosting: Rejilla (Tuning)

Búsqueda Exhaustiva

Probamos combinaciones de Shrinkage, Profundidad y MinObs.

Ganador: Shrinkage 0.1, Profundidad 6, MinObs 78.






shrinkage	interaction depth	n.minobsinnode	ntrees	dev
0.10	6	78	341	0.6276
0.05	6	78	476	0.6317
0.05	4	78	937	0.6325
0.10	4	156	380	0.6358
0.10	6	156	246	0.6368

Boosting: Modelo Definitivo

Resultados (Test)

- **AUC:** 0.9356
- **Accuracy:** 86.95%

PDP (Partial Dependence): Muestra relación sigmoide con la duración y picos claros en meses específicos.



Comparativa Global

Conclusiones

- **Potencia:** RF y Boosting ganan (AUC ~ 0.95).
- **Explicación:** GLM es ideal para entender el "por qué".

Recomendación: Usar Boosting para scoring y GLM para estrategia.

Modelo	Interpretabilidad	Complejidad	AUC Test	Estabilidad	Variables más relevantes
GLM (BIC)	Alta	Baja	≈ 0.91	Muy alta	duration, month, poutcome
Árbol podado	Muy alta	Media	≈ 0.88	Alta	duration, month
Lasso	Media	Baja	≈ 0.91	Muy alta	duration, month, poutcome
Random Forest	Baja	Alta	≈ 0.95	Muy alta	duration, month, poutcome
Gradient Boosting	Baja	Alta	≈ 0.94	Muy alta	duration, month, poutcome

¡Gracias!

Facultad de Estudios Estadísticos
Aprendizaje Supervisado II